Proyecto Modelos y Simulación II

Juan Camilo Morales Villada, Juan Sebastian Andraus Lopez, Jose Miguel Fajardo Fernandez
Universidad de Antioquia
Medellín

I. INTRODUCCIÓN

El análisis de datos relacionados con las reservas hoteleras permite identificar patrones asociados con el comportamiento de los clientes y las condiciones que pueden influir en la cancelación de una reserva. En este contexto, el aprendizaje automático ofrece herramientas útiles para construir modelos predictivos capaces de clasificar reservas a partir de variables como el tiempo de anticipación, tipo de hotel, duración de la estadía, segmento de mercado, tipo de depósito, tarifa diaria y características del cliente.

Este proyecto se enfoca en aplicar y evaluar técnicas de clasificación supervisada sobre el conjunto de datos Hotel Booking Demand, propuesto por Antonio, de Almeida y Nunes [1], y disponible públicamente para su análisis. El objetivo principal es desarrollar un modelo capaz de predecir si una reserva hotelera será cancelada o no. El dataset contiene 119.390 reservas correspondientes a dos hoteles y presenta variables relacionadas con las características de la reserva, el cliente y la estancia, por lo que constituye un problema de clasificación binaria basado en datos reales de reservas hoteleras.

II. DESCRIPCIÓN DEL PROBLEMA

La predicción de cancelaciones de reservas hoteleras constituye un problema relevante dentro del análisis de datos turísticos, ya que las cancelaciones pueden afectar la planificación de la ocupación, la disponibilidad de habitaciones y la gestión de los recursos del hotel. En este caso, el problema consiste en clasificar cada reserva en una de dos clases posibles: reserva no cancelada o reserva cancelada.

Una solución basada en Machine Learning resulta útil porque permite analizar de manera automática los patrones presentes en las reservas y construir modelos capaces de realizar predicciones sobre nuevas observaciones. La identificación anticipada de reservas con una mayor probabilidad de cancelación puede proporcionar información útil para la planificación hotelera y el análisis del comportamiento de los clientes. Por tanto, el propósito de este proyecto es principalmente académico: comparar diferentes modelos de clasificación, analizar su desempeño y estudiar el efecto de las diferentes etapas de preprocesamiento sobre los resultados obtenidos.

El conjunto de datos utilizado corresponde a Hotel Booking Demand, presentado por Antonio, de Almeida y Nunes [1], y compuesto por información relacionada con reservas de hoteles. El dataset contiene 119.390 registros correspondientes a dos tipos de hoteles: City Hotel y Resort Hotel. La versión utilizada en este proyecto fue obtenida de la plataforma Kaggle [2] y cuenta con 36 variables: las 32 del conjunto original y cuatro columnas adicionales (name, email, phone-number y credit_card) que fueron creadas de forma artificial por quien publicó esta versión, ya que en los datos originales se eliminó toda la información que permitía identificar a los clientes. Las observaciones incluyen información relacionada con las características de la reserva, las fechas de llegada, la duración de la estancia, el tipo de cliente, el segmento de mercado, las condiciones de depósito y diferentes características asociadas con la reserva. La variable objetivo del problema es is_canceled, que indica si una reserva fue cancelada o no. En la Tabla I se presenta un resumen de las variables del dataset.

TABLA I
RESUMEN DE LAS VARIABLES DEL DATASET

Tipo de variable	**Nombre**	**Descripción**
Categórica nominal	hotel	Identifica el tipo de hotel en el que se realizó la reserva: *City Hotel* o *Resort Hotel*.
Variable objetivo binaria	is_canceled	Indica si la reserva fue cancelada. Corresponde a la variable objetivo del problema de clasificación.
Numérica entera	lead_time	Número de días transcurridos entre la realización de la reserva y la fecha de llegada.
Variables temporales	arrival_date_year, arrival_date_month, arrival_date_week_number, arrival_date_day_of_month	Representan el año, mes, número de semana y día correspondientes a la fecha de llegada.
Numéricas enteras	stays_in_weekend_nights, stays_in_week_nights	Número de noches de estancia durante fines de semana y días entre semana.

Tipo de variable	Nombre	Descripción
Numéricas enteras	adults, children, babies	Cantidad de adultos, niños y bebés incluidos en la reserva.
Categórica nominal	meal	Tipo de plan de alimentación seleccionado para la reserva.
Categórica nominal	country	País de origen del huésped.
Categóricas nominales	market_segment, distribution_channel	Representan el segmento de mercado y el canal mediante el cual se realizó la reserva.
Binaria	is_repeated_guest	Indica si el huésped corresponde a un cliente recurrente.
Numéricas enteras	previous_cancellations, previous_bookings_not_canceled	Número de cancelaciones y reservas anteriores no canceladas asociadas con el cliente.
Categóricas nominales	reserved_room_type, assigned_room_type	Representan el tipo de habitación reservada y el tipo de habitación finalmente asignada.
Numéricas enteras	booking_changes, days_in_waiting_list, required_car_parking_spaces, total_of_special_requests	Representan cambios realizados en la reserva, días en lista de espera, espacios de parqueadero solicitados y solicitudes especiales.
Categórica nominal	deposit_type	Tipo de depósito asociado con la reserva.
Numérica continua	adr	Tarifa diaria promedio (*Average Daily Rate*) asociada con la reserva.
Categórica nominal	customer_type	Tipo de cliente asociado con la reserva.
Categóricas / identificadores	agent, company	Identifican, cuando están disponibles, el agente o la compañía asociados con la reserva.
Categórica nominal / fecha	reservation_status, reservation_status_date	Estado final de la reserva (*Canceled*, *Check-Out* o *No-Show*) y fecha en la que se registró dicho estado.
Texto (sintéticas)	name, email, phone-number, credit_card	Nombre, correo, teléfono y tarjeta de crédito del huésped. Fueron generadas artificialmente y no corresponden a clientes reales.

En cuanto a la variable objetivo, 75.166 reservas (62,96 %) no fueron canceladas y 44.224 (37,04 %) sí lo fueron, por lo que el conjunto presenta un desbalance moderado entre las dos clases. Esta proporción no es igual en ambos hoteles: en el City Hotel se canceló el 41,73 % de las reservas, mientras que en el Resort Hotel este valor fue de 27,76 %, como se observa en la Fig. 1(a). Por otro lado, la Fig. 1(b) muestra que la tasa de cancelación aumenta a medida que la reserva se realiza con mayor anticipación, pasando de 9,6 % en las reservas hechas con una semana o menos de antelación a 67,7 % en aquellas realizadas con más de un año de anticipación. Esto coincide con que lead_time es la variable numérica con mayor correlación con is_canceled (0,29).

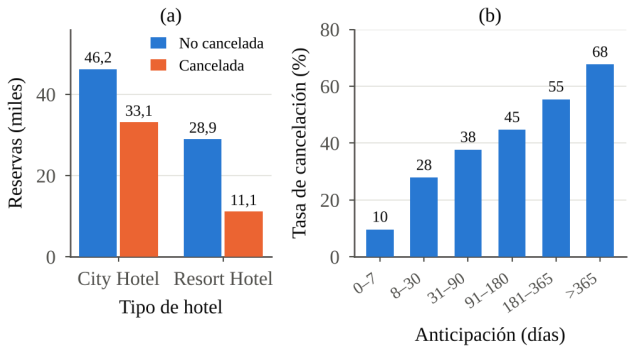


Fig. 1. (a) Número de reservas canceladas y no canceladas por tipo de hotel. (b) Tasa de cancelación según el tiempo de anticipación de la reserva (lead_time).

El dataset contiene variables de naturaleza numérica, categórica y binaria. Debido a esta diversidad, es necesario realizar un proceso de preparación de los datos antes del entrenamiento de los modelos. En particular, las variables categóricas deben transformarse a una representación

numérica que pueda ser utilizada por los algoritmos de Machine Learning.

El conjunto de datos presenta valores faltantes en cuatro variables: children, country, agent y company. En la Tabla II se muestra la cantidad y el porcentaje de valores faltantes de cada una, así como la estrategia de tratamiento definida a partir del análisis exploratorio.

TABLA II
VALORES FALTANTES Y ESTRATEGIA DE TRATAMIENTO

Variable	**Faltantes**	**%**	**Tratamiento**
children	4	0,003	Imputación con la moda (0)
country	488	0,41	Categoría adicional “Desconocido”
agent	16.340	13,69	Indicador binario: reserva con o sin agente
company	112.593	94,31	Indicador binario: reserva con o sin compañía

En el caso de agent y company, la ausencia de valor no corresponde a un error de registro, sino a que la reserva no se realizó por medio de un agente de viajes o de una compañía. Además, ambas variables son identificadores con 333 y 352 valores distintos, respectivamente, por lo que no tendría sentido tratarlas como variables numéricas ni codificar cada identificador por separado. Por esta razón, se reemplazarán por dos variables binarias que indican si la reserva tenía asociado un agente o una compañía. Para children, al tratarse solo de cuatro registros, se imputará el valor 0, que corresponde a la moda de la variable, y para country se creará una categoría adicional que represente la ausencia de información.

Adicionalmente, algunas variables categóricas contienen la categoría Undefined, que también representa ausencia de información aunque no aparezca como un valor nulo. Esto ocurre en meal (1.169 registros), market_segment (2 registros) y distribution_channel (5 registros). De acuerdo con la descripción original del dataset [1], en la variable meal las categorías Undefined y SC indican que la reserva no incluye plan de alimentación, por lo que ambas se agruparán en una sola categoría. En market_segment y distribution_channel, debido a la poca cantidad de registros, las reservas con esta categoría se eliminarán.

Durante la revisión de los datos también se identificaron algunos registros inconsistentes: 180 reservas sin huéspedes (con adults, children y babies iguales a cero), una reserva con tarifa diaria negativa (−6,38) y una con un adr de 5.400, valor muy superior al resto de los datos, teniendo en cuenta que el 75 % de las reservas tiene un adr menor o igual a 126. Estos registros se eliminarán, ya que no representan reservas válidas. Por otra parte, al retirar las columnas sintéticas se encontraron 31.994 filas repetidas (26,80 % del total). Como la base de datos no incluye un identificador de reserva, no es posible determinar si se trata de registros duplicados o de reservas diferentes con las mismas características, como puede ocurrir en las reservas de grupo. El tratamiento de estas filas se definirá en la configuración experimental, procurando que una misma observación no quede al mismo tiempo en los conjuntos de entrenamiento y prueba.

Por último, algunas variables no se utilizarán como entrada de los modelos. Las columnas name, email, phone-number y credit_card fueron generadas artificialmente, por lo que no aportan información sobre el comportamiento de las reservas. En el caso de reservation_status, esta variable indica el estado final de la reserva y coincide por completo con la variable objetivo: todas las reservas con estado Check-Out tienen is_canceled igual a 0, y todas las reservas con estado Canceled o No-Show tienen is_canceled igual a 1. Mantener esta variable, junto con reservation_status_date, generaría una fuga de información (data leakage), ya que el modelo tendría acceso directo a la respuesta que se quiere predecir. Algo similar ocurre con assigned_room_type, que ha sido excluida en trabajos previos por contener información que solo se conoce después de realizada la reserva [4]. En los datos se observa que las reservas cuya habitación asignada es diferente a la reservada tienen una tasa de cancelación de 5,38 %, frente a 41,56 % en las demás, por lo que esta variable también se excluirá. La variable country también ha sido señalada como una posible fuente de fuga de información [3], [4]; en los datos, Portugal corresponde al 62,32 % de las reservas canceladas y solo al 28,19 % de las no canceladas. Por esto, su inclusión se evaluará en la etapa experimental, comparando el desempeño de los modelos con y sin ella.

Para el procesamiento de las variables categóricas y numéricas se definió la siguiente estrategia de codificación:

Variables categóricas nominales: se aplicará One-Hot Encoding sobre variables como hotel, meal, country, market_segment, distribution_channel, reserved_room_type, deposit_type y customer_type, con el objetivo de transformar sus categorías en variables binarias sin establecer un orden artificial entre ellas. En el caso de country, que tiene 177 categorías distintas, los países con menos de 100 reservas (139 países que en conjunto suman 2.390 registros) se agruparán en una categoría “Otros” antes de la codificación, con el fin de evitar un aumento excesivo en el número de variables.

Variables binarias: variables como is_repeated_guest e is_canceled ya presentan una representación binaria, por lo que pueden mantenerse en formato numérico. Lo mismo ocurre con los indicadores creados a partir de agent y

company. La variable is_canceled será utilizada como variable objetivo, donde 0 representa una reserva no cancelada y 1 representa una reserva cancelada.

Variables numéricas: variables como lead_time, stays_in_weekend_nights, stays_in_week_nights, adults, children, babies, previous_cancellations, previous_bookings_not_canceled, booking_changes, days_in_waiting_list, adr, required_car_parking_spaces y total_of_special_requests serán mantenidas como variables numéricas. Para los modelos sensibles a la escala de los datos, se podrá aplicar una etapa de normalización o estandarización durante el preprocesamiento.

Variables temporales: las variables relacionadas con la fecha de llegada pueden mantenerse inicialmente como variables numéricas individuales o transformarse para generar características derivadas. Dado que arrival_date_month se encuentra como texto, se convertirá a su número de mes correspondiente (de 1 a 12). La estrategia definitiva dependerá del análisis exploratorio y de la evaluación de los modelos.

El análisis inicial del problema permite identificar que la variable objetivo corresponde a una clase binaria. Por esta razón, la aproximación de Machine Learning propuesta se basa en un paradigma de aprendizaje supervisado, específicamente en una tarea de clasificación binaria. Este enfoque es adecuado porque cada reserva del conjunto de datos cuenta con una etiqueta conocida que indica si la reserva fue cancelada o no. Además, como las clases no están balanceadas, la evaluación de los modelos no podrá basarse únicamente en la exactitud (accuracy), y será necesario considerar métricas como la sensibilidad, la precisión y el F1, así como particiones estratificadas que conserven la proporción de reservas canceladas en cada conjunto.

III. ESTADO DEL ARTE

La predicción de cancelaciones a partir de este conjunto de datos ha sido abordada en diferentes trabajos. En todos ellos el problema se plantea como una tarea de aprendizaje supervisado de clasificación binaria con is_canceled como variable objetivo, y en la mayoría se trabaja cada hotel por separado, identificando el Resort Hotel como H1 y el City Hotel como H2.

Adil et al. [3] compararon regresión logística, árboles de decisión, AdaBoost, Gradient Boosting y Random Forest, y evaluaron el efecto de dos técnicas de balanceo de clases, SMOTE y SMOTE-ENN. Antes del entrenamiento eliminaron variables como company, agent, country y reservation_status. Los hiperparámetros de Random Forest se ajustaron mediante búsqueda en malla con validación cruzada de 10 particiones. El mejor desempeño lo obtuvo Random Forest con SMOTE-ENN, con una exactitud superior al 95 % y una media geométrica (G-mean) de 95 % en H1 y 96,3 % en H2. Esta métrica combina la sensibilidad y la especificidad como se muestra en (1), donde TP y TN son los verdaderos positivos y negativos, y FP y FN los falsos positivos y negativos.

$$\text{G-mean} = \sqrt{\frac{TP}{TP+FN} \cdot \frac{TN}{TN+FP}} \tag{1}$$

Yang y Miao [4] propusieron una red neuronal basada en árboles (TNN), en la que la importancia de las variables obtenida con un modelo de árboles se utiliza para inicializar los pesos de una red neuronal de propagación hacia adelante. A diferencia del trabajo anterior, dividieron los datos de forma temporal, usando el 75 % de las reservas más antiguas para entrenamiento y el 25 % restante para prueba, con validación cruzada para series de tiempo dentro del conjunto de entrenamiento. Entre los modelos de árboles evaluados (Gradient Boosting, XGBoost, Random Forest y Extra Trees), el mejor AUC-ROC en prueba fue de 0,7718 en H1 y 0,7837 en H2, mientras que la TNN alcanzó 0,8554 y 0,8370, respectivamente. Además del AUC-ROC, los autores reportaron el área bajo la curva de precisión-sensibilidad (AUC-PR), la exactitud balanceada (BA) y el coeficiente de correlación de Matthews (MCC), definidos en (2), (3) y (4), donde P es la precisión y R la sensibilidad.

$$\text{AUC-PR} = \int_0^1 P(R)\, dR \tag{2}$$

$$\text{BA} = \frac{1}{2}\left(\frac{TP}{TP+FN} + \frac{TN}{TN+FP}\right) \tag{3}$$

$$\text{MCC} = \frac{TP \cdot TN - FP \cdot FN}{\sqrt{(TP+FP)(TP+FN)(TN+FP)(TN+FN)}} \tag{4}$$

Arasadina et al. [5] compararon Random Forest y XGBoost utilizando un flujo de preprocesamiento diseñado para evitar fugas de información, en el que la codificación y el tratamiento de valores atípicos se ajustan únicamente con los datos de entrenamiento. Usaron una partición estratificada de 70 %, 15 % y 15 % para entrenamiento, validación y prueba, búsqueda en malla con validación cruzada de 3 particiones y la prueba de McNemar para comparar los modelos. Random Forest obtuvo el mejor desempeño general, con un AUC-ROC de 0,9394, una exactitud de 0,8749 y un F1 de 0,8219, mientras que XGBoost alcanzó la mayor sensibilidad (0,8345). En Random Forest la variable más importante fue lead_time, y en XGBoost la coincidencia entre la habitación reservada y la asignada.

Finalmente, Silvestre, Antonio y Carrasco [6] trabajaron con 670.343 reservas de cuatro hoteles portugueses que siguen la misma estructura de este dataset. Usando

XGBoost, entrenaron un modelo con datos anteriores a la pandemia de COVID-19, con una partición estratificada de 67 % para entrenamiento y 33 % para validación, y lo evaluaron con reservas del periodo de pandemia, obteniendo valores de AUC entre 0,70 y 0,93. Luego aplicaron una ventana deslizante de 24 meses de entrenamiento y 9 meses de prueba, con la que el AUC se ubicó entre 0,85 y 0,99 en la mejor configuración, lo que muestra que los cambios en el comportamiento de los clientes a lo largo del tiempo afectan el desempeño de los modelos.

En los trabajos revisados, los ensambles de árboles, en especial Random Forest y XGBoost, obtienen los mejores resultados entre los modelos tradicionales. Sin embargo, el desempeño reportado depende en gran medida de la metodología de validación y del tratamiento de las variables con fuga de información. Por ejemplo, Random Forest alcanza un AUC-ROC de 0,9394 con una partición estratificada aleatoria [5], mientras que con una partición temporal el mejor modelo de árboles obtiene valores entre 0,77 y 0,78 [4]. Estos aspectos se tendrán en cuenta al definir la configuración experimental del proyecto.

REFERENCIAS

[1]N. Antonio, A. de Almeida y L. Nunes, “Hotel booking demand datasets,” *Data in Brief*, vol. 22, pp. 41–49, 2019, doi: 10.1016/j.dib.2018.11.126.

[2]Mojtaba, “Hotel Booking,” Kaggle, 2021. [En línea]. Disponible en: https://www.kaggle.com/datasets/mojtaba142/hotel-booking

[3]M. Adil, M. F. Ansari, A. Alahmadi, J.-Z. Wu y R. K. Chakrabortty, “Solving the problem of class imbalance in the prediction of hotel cancelations: A hybridized machine learning approach,” *Processes*, vol. 9, no. 10, Art. no. 1713, 2021, doi: 10.3390/pr9101713.

[4]D. Yang y X. Miao, “Predicting hotel booking cancellations using tree-based neural network,” *PeerJ Computer Science*, vol. 10, Art. no. e2473, 2024, doi: 10.7717/peerj-cs.2473.

[5]F. Arasadina, S. Briandoko y M. A. Setiawan, “Prediksi pembatalan pemesanan hotel: Random Forest dan XGBoost dengan pipeline leak-free dan ablation study,” *MALCOM: Indonesian Journal of Machine Learning and Computer Science*, vol. 6, no. 3, pp. 1018–1030, 2026, doi: 10.57152/malcom.v6i3.2674.

[6]P. Silvestre, N. Antonio y P. Carrasco, “Navigating uncertainty: enhancing hotel cancellation predictions with adaptive machine learning,” *Information Technology & Tourism*, vol. 28, no. 1, Art. no. 9, 2026, doi: 10.1007/s40558-025-00349-9.